

Assignment 4 - Report

Shahar Oded, 208388918
Nir Rahav, 316275437

הקמה של ה-TabularDataset:

אנחנו מתעסקים פה עם דאטה טבלאי, פשוט יחסית, עבורו אנחנו יודעים לתכנן מראש את הערכים הייחודיים בכל עמודה ואת הסוג שלהם. נציג מידע סיכומי על הדאטה:

[Info]: Number of rows: 32561
[Info]: Number of columns: 15

[Info]: Target class distribution:
income
b'<=50K' 0.75919
b'>50K' 0.24081

[Info]: Categorical columns: 9
[Info]: Continuous columns: 6
[Info]: Number of columns after one-hot encoding: 101 == Embedding Vector Dimension

אנחנו רואים פה imbalance בעמודת ה-target אבל לא משהו מאוד חריג. נרצה לבצע stratified split כשנעסוק בחלקים מהדאטה הזו. כמו כן נרצה לאפשר ביצוע אוגמנטציה באמצעות oversampling עם הרעשה רנדומית של המשתנים הנומריים (בעד כדי 0.05) על מנת להוסיף קצת גיוון בערכים בזמן האוגמנטציה ולנסות למנוע מצב של mode collapse בו ה-generator לומד ייצוגים של ה-majority class בלבד. כמו כן, את הערכים הקטגוריאליים נתרגם באמצעות one-hot-encoder לכניסות נפרדות, ואת הערכים הנומריים ננרמל באמצעות MinMaxScaler. את עמודת ה-target נציג בתור כניסה בודדת עם "1" עבור b'>50K ו"0" עבור b'<=50K.

יצרנו בנוסף TabularDatasetFromArrays משני שתפקידו לקחת אובייקט מהראשי אחרי ביצוע Stratified Split ולהפוך חזרה לאובייקט אותו ניתן להפוך ל-dataloader. היות ונשתמש בפונקציית TanH כדי לייצר את הוקטור היוצא מה-generator באקטיבציה הסופית, העברנו את כל הנתונים להיות בטווח של [-1,1].

אחרי שימוש בפונקציית החלוקה אנחנו רואים שימור של היחסים בתוך כל label:

[Main]: Class distributions after split:
Train (26048 labels): 0 -> 0.759175
1 -> 0.240825
Test (6513 labels): 0 -> 0.759251
1 -> 0.240749

ואם אנחנו בוחרים להשתמש באוגמנטציה:

[Main]: Class distributions after split:
Train (39550 labels): 1 -> 0.5
0 -> 0.5
Test (6513 labels): 0 -> 0.759251
1 -> 0.240749

הוספנו האפשרות לחלוקה גם ל-val_set מתוך ה-train (לפני אוגמנטציה). נבין בהמשך אם זה תורם להתמודדות עם הבעיה.

על מנת לטפל בבעיה עתידית, בה המודל לא יוכל לתת ערכים קטגוריאליים (אלא רק רציפים), שמרנו באובייקט גם מיפוי של כל האינדקסים של עמודות ה-one-hot, כך שפונקציית generate תוכל לעשות להם עיגול לערך 1 או 0 בהתאמה. כך נוכל לג'נרט רשומות אמינות יותר, לפחות בהיבט הזה.

הגדרת מודל GAN:

בדומה לעבודות קודמות, רצינו להשאיר את הקונפיגורציה של השכבות בתור פרמטר חיצוני וברור המגדיר לכל שכבה גדלים, אקטיבציות, batch norm ו-dropout. ניתן לראות את הקונפיגורציות בהן בחרנו ב-config.py:

```
# Model Config
DATA_DIM = 100 # The size of the feature vector
NOISE_DIM = 32 # The size of the initial noise vector

## Generator Configuration
GENERATOR_CONFIG = [
    {"input_dim": NOISE_DIM, "output_dim": 64, "activation": nn.LeakyReLU(0.2), "batch_norm": True, "dropout": 0.2},
    {"input_dim": 64, "output_dim": 128, "activation": nn.LeakyReLU(0.2), "batch_norm": True, "dropout": 0.2},
    {"input_dim": 128, "output_dim": 256, "activation": nn.LeakyReLU(0.2), "batch_norm": True, "dropout": 0.2},
    {"input_dim": 256, "output_dim": 512, "activation": nn.LeakyReLU(0.2), "batch_norm": True, "dropout": 0.3},
    {"input_dim": 512, "output_dim": 256, "activation": nn.LeakyReLU(0.2), "batch_norm": True, "dropout": 0.2},
    {"input_dim": 256, "output_dim": DATA_DIM, "activation": nn.Tanh(), "batch_norm": False, "dropout": 0.0}, # No dropout on
the last layer
]

## Discriminator Configuration
DISCRIMINATOR_CONFIG = [
    {"input_dim": DATA_DIM, "output_dim": 64, "activation": nn.LeakyReLU(0.2), "batch_norm": False, "dropout": 0.2},
    {"input_dim": 64, "output_dim": 32, "activation": nn.LeakyReLU(0.2), "batch_norm": False, "dropout": 0.2},
    {"input_dim": 32, "output_dim": 1, "activation": nn.Sigmoid(), "batch_norm": False, "dropout": 0.0}, # No dropout on the
output layer
]
```

בדומה לתרגול בחרנו להשתמש בפונקציות אקטיבציה LeakyRelu, כך שה output של ה-generator יהיה באמצעות TanH, ועבור ה-discriminator בחרנו להשתמש ב-output של sigmoid הרי שהבעיה היא בינארית. רצינו לייצר ארכיטקטורה מורכבת יותר עבור ה-generator שתגדיל בהדרגה את הייצוג של ווקטור הרעש ההתחלתי המוזן לו ולבסוף תתכוון לגודל DATA_DIM (מבנה פירמידה). עבור ה-discriminator רצינו לייצר ארכיטקטורה פשוטה יותר שתשרת משימת קלאסיפיקציה יחסית "קלה". בהתאם לתוצאות האימון נשקול שינויים במודלים. המודל מקבל וקטור רעש בגודל NOISE_DIM בגודל 32 וממנו מג'נרט את הדגימה. בחרנו ברעש הקטן מ-DATA_DIM לאור המלצה, על מנת שזה יתרחב בהדרגה לאורך שכבות המודל. הפרמטרים של המודל מוגדרים גם הם חיצונית:

```
APPLY_AUGMENTATION = False # Apply augmentation on minority classes when stratified split is called.
BATCH_SIZE = 128
VAL_RATIO = 0.0 # Ratio out of the training dataset
TEST_RATIO = 0.2 # Ratio out of the full dataset
SEED = 42 # Change the seed and check influence on the model


# Training Config
LEARNING_RATE = 5e-4 # Initial learning rate
WEIGHT_DECAY = 1e-5
EARLY_STOP = 50 # Stop after |EARLY_STOP| epochs with no improvement in the total loss
WARMUP_EPOCHS = 50 # Define a number of warmup iterations in which the model won't count towards an early stop.
EPOCHS = 500 # A high number of epochs, hoping for an early stopping
GENERATOR_UPDATE_FREQ = 1 # Number of G updates per D updates, to balance their losses.
```

המודל מאמן את שני חלקיו יחד בתוך פונקציית train, כאשר הגדרנו פרמטר GENERATOR_UPDATE_FREQ המאפשר לאמן את הגנרטור יותר מאשר את הדיסקרימיננטור במקרה של שיפור מואץ שלו על פניו. התנסנו עם פרמטר זה אך ללא המון הצלחה ניכרת. לתחושתנו, ניסוי זה גרם בכלל לפערים יותר משמעותיים בין השניים. הגדרנו בתהליך האימון לשמור בכל נקודות שיפור את המשקלים של המודל הטוב ביותר על מנת שנוכל לשחזר המודלים מבלי לאמן אותם מחדש. המודל הטוב ביותר נקבע ע"י ערכי ה-loss של הג'נרטור, היות והמטרה היא לייצר דגימות מזויפות משכנעות, ולכן נקבע שיפור ע"י ירידה ב-loss שלו המופק מחיזוי ה-discriminator. עם זאת, בתהליך האימון נרצה להיות ערניים לירידת ה-loss של ה-discriminator כדי לוודא שהוא בעצמו מצליח ללמוד להבחין בין הווקטורים, ונשאיר יחסית מאוזן. הגדרנו גם עצירה מוקדמת אם אין שיפור בערך זה אחרי k אפוקים, כך שבפועל כל מודל יתאמן לפחות 100 epochs, אבל יתכן וימצא את האופטימום שלו אחרי האיטרציה ה-50, או מתישהו בהמשך. עצירה כפויה אחרי 500 איטרציות.

המודל עובד עם אופטימיזר ADAM עבור שני המודלים, עם LR ו-W2 כמופיע בתמונה ועם פונקציית loss מסוג BCELoss לאור האופי הבינארי של הבעיה. מספר האפוקים הסופי של כל מודל יופיע בתיעוד האימון שלו. לאור ירידת ה-loss הלא יציבה לא ראינו לנכון לממש scheduler בארכיטקטורה זו. בניסיון נוסף לאזן עוד יותר בין המודלים הגדרנו W2 רק עבור הדיסקרימיננטור, עם LR הקטן פי 10 מזה של הג'נרטור, אבל לא הצלחנו להצביע באמצעות זה על שיפור.

תהליך האימון:

אפשר לראות שבהתחלה קל מאוד ל-generator להטל ב-discriminator ולכן ערכי ה-loss שלו טובים יותר. לאחר מספר אפוקים ה-discriminator מבין את בעיית הסיווג ומתחיל להשתפר בה. אנחנו רצינו לאפשר למודל לעצור בנקודת מינימום לוקאלית של ה-generator אחרי ששני המודלים כבר למדו להגיב אחד לשני ושה-loss יחסית יציב. כך בחרנו את ערכי העצירה.



```
[Training Status]: Epoch 1: Generator Loss: 0.7351, Discriminator Loss: 1.1036
[Training Status]: Epoch 2: Generator Loss: 0.7505, Discriminator Loss: 1.3043
[Training Status]: Epoch 3: Generator Loss: 0.7176, Discriminator Loss: 1.3592
[Training Status]: Epoch 4: Generator Loss: 0.7282, Discriminator Loss: 1.3425
[Training Status]: Epoch 5: Generator Loss: 0.7483, Discriminator Loss: 1.3446
[Training Status]: Epoch 6: Generator Loss: 0.7587, Discriminator Loss: 1.3431
[Training Status]: Epoch 7: Generator Loss: 0.7593, Discriminator Loss: 1.3415
[Training Status]: Epoch 8: Generator Loss: 0.7724, Discriminator Loss: 1.3283
[Training Status]: Epoch 9: Generator Loss: 0.7996, Discriminator Loss: 1.3119
[Training Status]: Epoch 10: Generator Loss: 0.8027, Discriminator Loss: 1.3086
.
.
.
[Training Status]: Epoch 43: Generator Loss: 1.6068, Discriminator Loss: 0.8121
[Training Status]: Epoch 44: Generator Loss: 1.6317, Discriminator Loss: 0.8038
[Training Status]: Epoch 45: Generator Loss: 1.6171, Discriminator Loss: 0.8217
[Training Status]: Epoch 46: Generator Loss: 1.5473, Discriminator Loss: 0.8879
[Training Status]: Epoch 47: Generator Loss: 1.5326, Discriminator Loss: 0.8666
[Training Status]: Epoch 48: Generator Loss: 1.5716, Discriminator Loss: 0.8205
[Training Status]: Epoch 49: Generator Loss: 1.6530, Discriminator Loss: 0.7974
[Training Status]: Epoch 50: Generator Loss: 1.5814, Discriminator Loss: 0.8381
[Training Status]: Epoch 51: Generator Loss: 1.6237, Discriminator Loss: 0.8303
Model saved to Trained Models\gan\best_model.pth
[Training Status]: Epoch 52: Generator Loss: 1.5926, Discriminator Loss: 0.8374
Model saved to Trained Models\gan\best_model.pth
[Training Status]: Epoch 53: Generator Loss: 1.6450, Discriminator Loss: 0.7793
[Training Status]: Epoch 54: Generator Loss: 1.6147, Discriminator Loss: 0.8183
[Training Status]: Epoch 55: Generator Loss: 1.5841, Discriminator Loss: 0.8315
Model saved to Trained Models\gan\best_model.pth
[Training Status]: Epoch 56: Generator Loss: 1.6618, Discriminator Loss: 0.8072
[Training Status]: Epoch 57: Generator Loss: 1.6732, Discriminator Loss: 0.7956
[Training Status]: Epoch 58: Generator Loss: 1.6836, Discriminator Loss: 0.7713
[Training Status]: Epoch 59: Generator Loss: 1.7973, Discriminator Loss: 0.7205
[Training Status]: Epoch 60: Generator Loss: 1.7339, Discriminator Loss: 0.7531
[Training Status]: Epoch 61: Generator Loss: 1.7205, Discriminator Loss: 0.7589
.
.
.
[Training Status]: Epoch 105: Generator Loss: 1.6173, Discriminator Loss: 0.7763
[Training Status]: Early stopping triggered!
```

הגדרת מודל cGAN:

על מנת לעשות הסבה של המודל הקודם הגדרנו מחלקה יורשת בה יש פרמטר נוסף, NUM_CLASSES. האופי המודולרי של הקוד אפשר לנו באמצעות שינויים מינימליים (למשל הגדלת ה-input dimension של השכבה הראשונה) להשתמש באותו המבנה. בפונקציית ה-train היינו צריכים עכשיו לדאוג להעביר לשני חלקי המודל לצד הוקטור z את ה-label האמיתי של הדגימה, המועברת ע"י ה-dataloader (ומקודם פשוט לא נעשה בה שימוש).





Figure 1: the conditional GAN architecture

בניגוד למודל הקודם, שאם היה מג'נרט דגימות לפי מחלקה 1 או 0 זה היה כתלות בלבד בהתפלגות הפיצ'רים שלהם במרחב, המודל הזה מנסה ללמוד את ההתפלגות של כל מחלקה בנפרד, ואז מייצר דגימות יותר מפוקסות למחלקה זו, לפי דרישה.

תהליך האימון:

שמנו לב שמודל זה לוקח יותר איטרציות עד שמגיע ל-early stop, מפה אנחנו מניחים שהוספת האינפורמציה עוזרת לו בביצועים, ומייצרת מצב "פינג-פונג" יותר מעניין בין ביצועי ה-generator לביצועי ה-discriminator.



Epoch 1: Generator Loss: 0.8140, Discriminator Loss: 1.0400
 Epoch 2: Generator Loss: 0.7986, Discriminator Loss: 1.3144
 Epoch 3: Generator Loss: 0.7426, Discriminator Loss: 1.3361
 Epoch 4: Generator Loss: 0.7584, Discriminator Loss: 1.3308
 Epoch 5: Generator Loss: 0.7772, Discriminator Loss: 1.3216
 Epoch 6: Generator Loss: 0.7668, Discriminator Loss: 1.3375
 Epoch 7: Generator Loss: 0.7841, Discriminator Loss: 1.3240
 Epoch 8: Generator Loss: 0.7996, Discriminator Loss: 1.3150
 Epoch 9: Generator Loss: 0.8016, Discriminator Loss: 1.3123
 Epoch 10: Generator Loss: 0.8273, Discriminator Loss: 1.2942

.
 .
 .

Epoch 49: Generator Loss: 1.5597, Discriminator Loss: 0.8650
 Epoch 50: Generator Loss: 1.6252, Discriminator Loss: 0.8139
 Epoch 51: Generator Loss: 1.5815, Discriminator Loss: 0.8455
 Model saved to Trained Models\cgan\best_model.pth
 Epoch 52: Generator Loss: 1.5672, Discriminator Loss: 0.8577

.
 .
 .

Epoch 95: Generator Loss: 1.4421, Discriminator Loss: 0.8851
 Model saved to Trained Models\cgan\best_model.pth
 Epoch 96: Generator Loss: 1.4879, Discriminator Loss: 0.8641
 Epoch 97: Generator Loss: 1.5178, Discriminator Loss: 0.8456

.
 .
 .

Epoch 146: Generator Loss: 1.4023, Discriminator Loss: 0.8809
 Model saved to Trained Models\cgan\best_model.pth
 Epoch 147: Generator Loss: 1.4458, Discriminator Loss: 0.8760

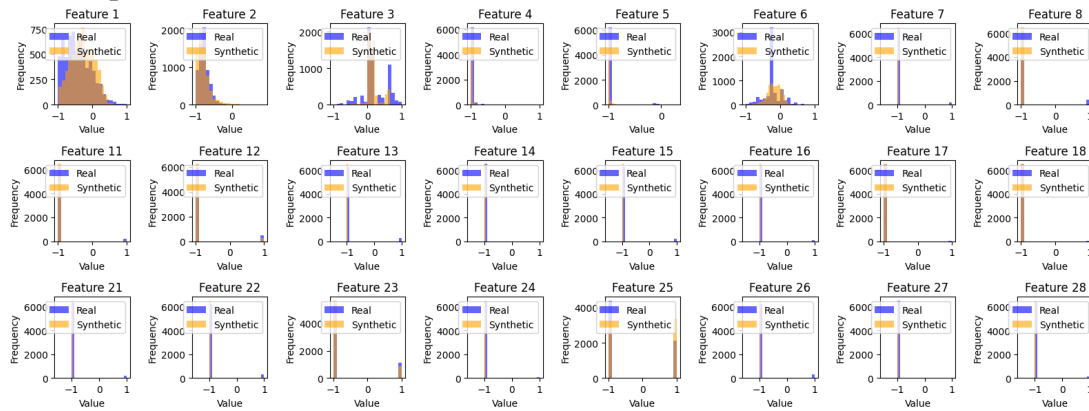
.
 .
 .

Epoch 196: Generator Loss: 1.4675, Discriminator Loss: 0.8738
 [Training Status]: Early stopping triggered!

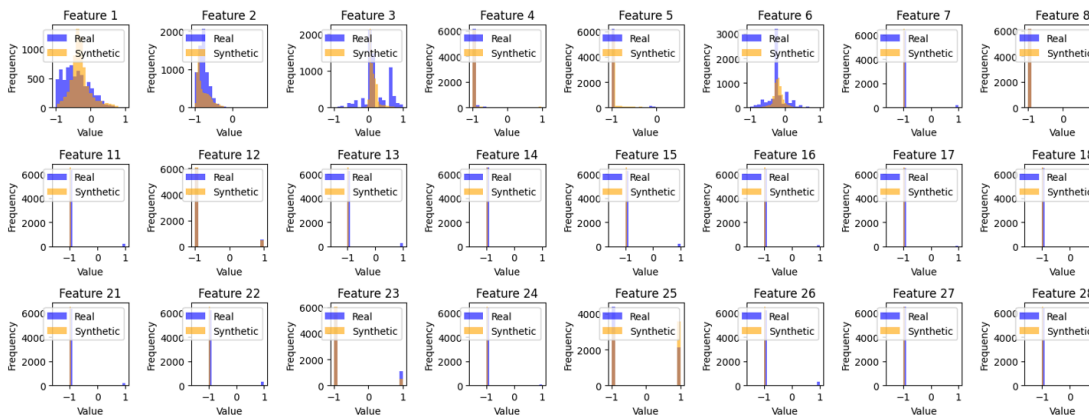
ביצוע Feature Analysis:

בשלב ראשון רצינו לבחון את התפלגויות הנתונים הנוצרים מה-GAN ומה-cGAN. בתמונות 6 הפיצ'רים הראשונים הם נומריים והיתר קטגוריאליים.

GAN (top few):



cGAN (top few):

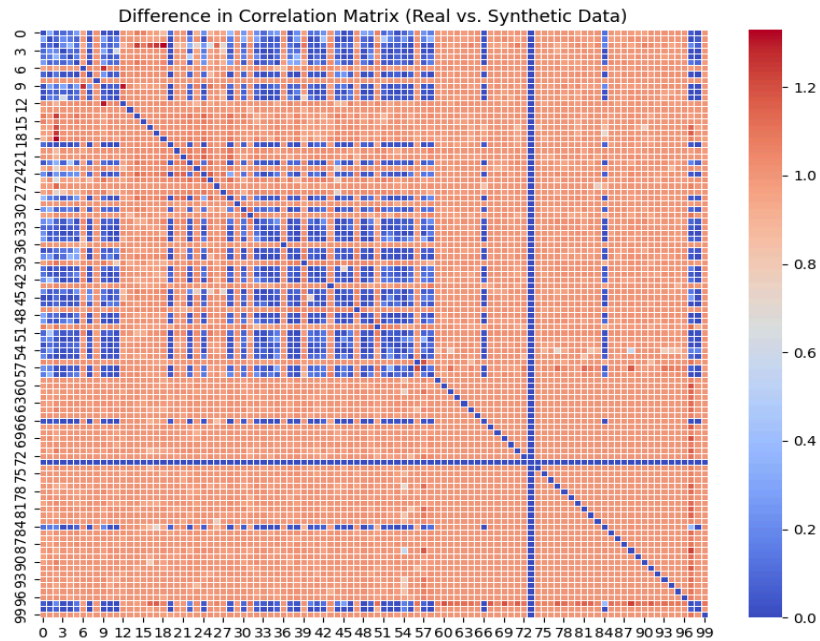


בבדיקה זו, לדעתנו, מודל ה-GAN מציג התפלגויות מעט יותר קרובות למציאות, עם פחות מרכז סביב ערכים ספציפיים. התרשימים מראים לנו שהמודלים מצליחים בסך הכל לייצר גם את הערכים הנומריים וגם הערכים הקטגוריאליים, בהתפלגויות יחסית דומות למקור. אם למשל היינו רואים "פעמון" באיזור שונה בסקאלה מזה בו הנתונים האמיתיים נמצאים - היינו דואגים. זה לא ממש המצב, למרות שכן ניתן לראות סטייה מסוימת עבור feature 1. בדיקה זו היא ראשונית ונחמדה, אבל בשלבים הבאים נרצה לבחון האם הנתונים אמנים. האם רשומה מסוימת משכנעת אותנו שהיא אמיתית.

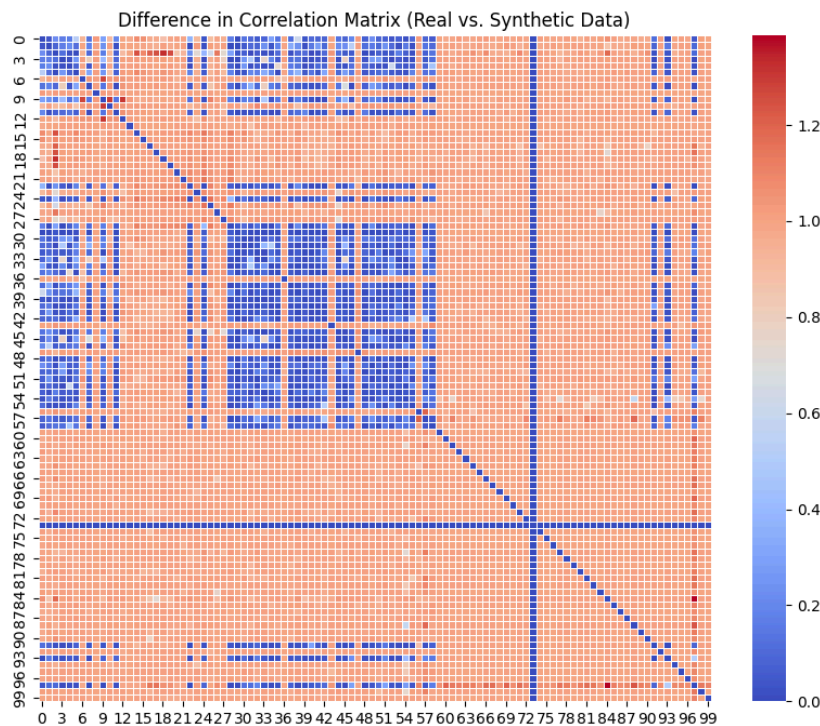
לשם כך בשלב ראשון נבדוק את הקורלציות בין הפיצ'רים, והאם דומות לקורלציות בין הפיצ'רים בנתונים האמיתיים. על מנת לפרשן יותר בקלות, יצרנו מטריצת קורלציות המראה את ההפרשים בקורלציות בתוך הנתונים המזויפים למול בתוך הנתונים האמיתיים.

בפשטות יחסית, התמונה בה הצבע הכחול שולט יותר מציגה לנו למעשה שההבדלים בקורלציות בין הפיצ'רים שלו יותר קטנים, ז"א שהוא יחסית מייצג יותר את היחסים בין הפיצ'רים. באופן שלא מאוד מפתיע, מודל ה-cGAN יצר זאת באופן יותר משכנע:

GAN:



cGAN:



לסיכום של בדיקה זו - הנתונים המיוצרים חד משמעית אינם מושלמים, ויש איזורי חולשה משמעותיים בהם נראה שגם אם התפלגויות הנתונים יחסית נשמרות, הקורלציות בין הנתונים לא. סביר להניח שכשנסה להשתמש בנתונים אלו לאימון מודל, הוא יוכל להבחין שאינם קוהרנטיים עם עצמם, ושהקורלציות לא נשמרות.

קיימת הבעיה של הערכים הקטגוריאליים, בהם בפרט נראה ששני המודלים מתקשים (לאור כך שהאינדקסים ה"אדומים" הם לא של הערכים הרציפים - אינדקס 6 ומעלה הם קטגוריאליים). ייתכן שהפתרון שלנו של עיגול הערכים עבור עמודות מסומנות מראש הוא אגרסיבי מידי ויוצר אי דיוקים בדאטה הסינטטי, ושנדרשים פתרונות אחרים, עדינים יותר, כדי לעשות זאת (למשל, אימון מודל AE מתאים).

ביצוע הערכה לדאטה הסינטי באמצעות detection & efficiency:

בשלב הראשון, בהתאם לבקשה, ניקח את ה-`train_set` ו-`generated set` באותו הגודל ובאמצעות CV 4 folds עליו נאמן מודל RF על 75%, ועבור ה-25% הנוספים נבדוק האם המודל מצליח להבחין בין הדגימות האמיתיות והמזויפות. כל הדגימות האמיתיות יסומנו ב-1 וכל המזויפות ב-0. לצערנו, בשלב זה, לא הצלחנו בכלל לעבוד על מודל ה-RF, והוא הצליח להבחין באופן מלא בין הדגימות האמיתיות לבין המזויפות (Average AUC for detection: 1.0000) גם עם מודל ה-GAN וגם עם ה-cGAN.

בשלב השני נרצה לבדוק האם הדגימות המג'ונרטות מהוות חליף טוב לדגימות האמיתיות ע"י אימון מודל RF פעם אחת לדאטה האמיתי ופעם אחת למזויף. אם אותו המודל מצליח להגיע לציון AUC דומה בין שני ה-`settings` על ה-`test set` סימן שהדאטה שימושי. נבחן ע"י היחס בין שני הציונים: `Real AUC\Fake AUC`. עבור בדיקה זו קיבלנו `Efficacy Score: 0.63` במוצע עבור מודל ה-cGAN, לאורך 3 ניסויי SEED שונים, ציון שאינו טוב במיוחד, היות והבעיה היא בעיית סיווג בינארית. מודל ה-GAN קיבל ציון ממוצע נמוך יותר - 0.56 - פער שאינו מפתיע היות והקורלציות בין הפיצ'רים הנוצרים ע"י ה-GAN פחות טובות.

הביצועים הגרועים בשני המדדים מראים שכנראה למידע הסינטי יש סממנים מסגירים. אנו מניחים שמדובר בעמודות הקטגוריאליות עבורן המודלים מתקשים לסמן ערך אחד בלבד בכל מקבץ עמודות המייצגות עמודה מקורית אחת. תהליך הלמידה המשמעותי הנדרש פה הוא שעבור k העמודות המייצגות פיצ'ר מקורי אחד, רק 1 תקבל את הערך True, ואנחנו מניחים ששם המודל מתקשה לבצע, הרי שמספיקה קבוצת עמודות אחת המסומנת לא טוב על מנת שהמודל ידע שמדובר בדגימה מזויפת.